

词法分析

任务

- 词法分析器读入Mandrill源程序，将其分割成有意义的词素。对于每个词素，产生词法单元输出。
- Mandrill 是一门为编译原理课程设计的命令式编程语言。v2.0 版本在 v1.0 极简主义的基础上，引入了动态内存管理、UTF-32 字符串支持以及完整的函数调用机制。

Mandrill的词法单元描述

- 字符集

- √ 源代码使用UTF-8 编码。

- √ 标识符字符：小写字母 a-z、大写字母A-Z、下划线_。

- √ 数字：0-9。

- √ 运算符与分隔符：+ - * / % < > = ! () [] { } , ; ' "。

- √ 不可见字符：空格、换行、回车、制表符仅用于分割词素。

- 注释：行注释，自 `#` 起至行尾的内容将被忽略。

Mandrill的词法单元描述 (2)

- 词素 (Tokens)

- √ 关键字: ``if``, ``else``, ``while``, ``read``, ``put``, ``write``, ``get``, ``func``, ``global``, ``local``, ``return``, ``break``, ``continue``。
- √ 整数常量: 十进制表示, 不设负数 (通过 ``0 - x`` 获得), 长度不超过 8 位。
- √ 字符常量: 单引号围绕, 支持 ``\n``, ``\\``, ``\'``。
- √ 字符串常量: 双引号围绕。在编译时, 字符串被转换为 UTF-32 编码 (每个字符 4 字节), 并以 ``0`` 结尾。

记号类型

[illegible]

记号的数据结构

```
1 package cn.edu.fzu.ccds.compilerprinciples.mandrill.lexer.tokens;
2
3 public class Token {
4     public final TokenType type;
5     public final String lexeme;
6     public final int line;
7     public final int column;
8
9     public Token(TokenType type, String lexeme, int line, int column) {
10         this.type = type;
11         this.lexeme = lexeme;
12         this.line = line;
13         this.column = column;
14     }
```

测试用例

输入

```
write = read + 1;  
put = '\n';
```

输出

Ln 1	, Col 1	WRITE	'write'
Ln 1	, Col 7	ASSIGN	'='
Ln 1	, Col 9	READ	'read'
Ln 1	, Col 14	PLUS	'+'
Ln 1	, Col 16	INT_CONST	'1'
Ln 1	, Col 17	SEMI	';'
Ln 2	, Col 1	PUT	'put'
Ln 2	, Col 5	ASSIGN	'='
Ln 2	, Col 7	CHAR_CONST	'\n'
Ln 2	, Col 11	SEMI	';'
Ln 3	, Col 1	EOF	'<EOF>'

编程

```
public class HandcraftLexer {  
    private final PushbackReader reader;  
  
    public List<Token> scanTokens() {  
        List<Token> tokens = new ArrayList<>();  
        tokens.add(new Token(TokenType.WRITE, "write", 1, 1));  
        tokens.add(new Token(TokenType.ASSIGN, "=", 1, 7));  
        return tokens;  
    }  
}
```

// 这两个函数不要进行改动 以下省略

A.3词法分析器（P612）

(1)Tag类定义部分记号对应的常量（内部表示）。

(2) Token是描述所有记号的基类，它有一个数据成员tag以区分不同记号，构造函数赋tag值。

(3)Num是描述整数的类，派生于Token，增加了一个数据成员value（词素，注意它的类型），它的构造函数在利用基类构造函数初始化tag值后，还给value赋了值。

(4)Word(P613)描述保留字、标识符和各种复合运算符，派生于Token，增加了一个数据成员lexeme，它的构造函数有两个参数（前面是词素，后面是记号值）。7至13行定义一些Word类的常量。

(5)Lexer是完成词法分析功能的类，数据成员line为行号，peek是向前的一个字符，words是符号表。成员函数reserve将给定记号加入符号表。它的构造函数(8至17行)将所有保留字加入符号表。

A.3词法分析器（P612）

(6) `readch`(18至24行)是Lexer的成员函数，它是重载的，可以有参数也可无参数。无参数时，直接读入一个字符到`peek`，无返回；有参数时，读入字符到`peek`，并与所给参数比较，相同时返回`true`，否则为`false`。

(7) `scan`(P614页25至74行) 是完成主要词法分析功能的函数：26-30行，处理空白类字符，31至44行处理一系列运算符；45-58处理数字；59-70行处理标识符（或保留字）；在无法处理时，将单个字符作为词素，其记号值为对应ASCII值。本函数返回记号。